AATEC - ÁREA DE AGRÁRIAS, ENGENHARIAS E TECNOLOGIAS
CURSO DE SISTEMAS DE INFORMAÇÃO
ABEX VI: PROJETO INTEGRADO III
RESUMO EXPANDIDO 1

ANÁLISE DE FATORES ASSOCIADOS À GRAVIDADE DE ACIDENTES EM RODOVIAS FEDERAIS DA REGIÃO SUL DO BRASIL

Integrantes: João Wictor Decarli; Rafael Lucas Rockenbach; Gabriel Victor Rosario; Bernardo Dal Piva Bernardi
Turma: BX Data: 08/10/2026

Palavras-chave: acidentes de trânsito; rodovias federais; análise exploratória de dados; classificação de gravidade; PRF.

1 INTRODUÇÃO

Os acidentes de trânsito em rodovias federais representam um problema de saúde pública e de segurança viária de grande relevância no Brasil. Na Região Sul, os estados de Santa Catarina, Paraná e Rio Grande do Sul concentram volume expressivo de tráfego federal, com características geográficas e climáticas diversas que podem influenciar a ocorrência e a gravidade dos acidentes. Compreender quais fatores estão associados a desfechos mais graves é fundamental para subsidiar ações preventivas por parte da Polícia Rodoviária Federal (PRF) e do Departamento Nacional de Infraestrutura de Transportes (DNIT).

O projeto parte dos dados abertos de acidentes registrados pela PRF, disponibilizados no portal de dados abertos da instituição, e aplica técnicas de análise exploratória de dados (EDA), pré-processamento e, em etapa posterior, modelagem preditiva para identificar padrões associados à gravidade dos acidentes.

1.1 Problema e objetivo do projeto

Problema investigado: Quais fatores de contexto, como condições da via, horário, causa do acidente e tipo de pista, estão associados à maior gravidade dos acidentes em rodovias federais da Região Sul?

Objetivo geral: Identificar e quantificar a associação entre variáveis de contexto e a gravidade dos acidentes de trânsito registrados pela PRF nos estados de SC, PR e RS em 2026, com o intuito de fornecer subsídios para ações preventivas da PRF e do DNIT.

Objetivos específicos:

- Caracterizar a base de dados da PRF quanto à qualidade, completude e distribuição das variáveis;
- Realizar análise exploratória descritiva e investigar relações entre variáveis explicativas e a gravidade dos acidentes;
- Construir um modelo de classificação para prever se um acidente resultará em vítima grave ou fatal, usando apenas variáveis de contexto conhecidas antes do desfecho.

2 BASE DE DADOS E PROCEDIMENTOS METODOLÓGICOS

2.1 Origem e caracterização dos dados

Item	Descrição
Fonte dos dados	Portal de dados abertos da Polícia Rodoviária Federal: portal.prf.gov.br/dados-abertos-acidentes
Período	01/01/2026 a 31/05/2026 (5 meses)
Formato	CSV (separador ponto e vírgula, encoding UTF-8)
Dimensão inicial	8.703 linhas x 30 colunas
Unidade de análise	Uma ocorrência de acidente de trânsito em rodovia federal
Bases integradas	Não aplicável: utilizou-se apenas o recorte da Região Sul (SC, PR e RS) extraído da base "por ocorrência" (datatran)

Fonte: elaborada pelos autores.

A base é composta por uma linha por ocorrência de acidente. O identificador único é a coluna *id*, sem duplicatas. A distribuição geográfica é: Santa Catarina com 3.538 registros (40,6%), Paraná com 3.254 (37,4%) e Rio Grande do Sul com 1.911 (22,0%).

2.2 Limpeza e pré-processamento dos dados

O pré-processamento seguiu o fluxo proposto pelo professor: abrir a base, realizar EDA, identificar problemas, investigar, decidir, tratar e validar. Todas as decisões foram registradas em log com justificativa e quantidade de registros afetados.

Os principais procedimentos realizados foram:

Conversão de tipos: A coluna *data_inversa* (formato texto dd/mm/aaaa) foi convertida para datetime, permitindo extrair *mes* (1 a 5) e *dia_semana_num*. A coluna *horario* (texto hh:mm:ss) gerou a variável *hora* (0 a 23). As colunas *km*, *latitude* e *longitude* usavam vírgula decimal e estavam como texto; foram convertidas para numérico com *pd.to_numeric(errors="coerce")*.

Criação de variáveis: Foram criadas as variáveis *fim_de_semana* (binária), *faixa_horaria* (Madrugada 0-5h, Manhã 6-11h, Tarde 12-17h, Noite 18-23h) e duas variáveis de desfecho: *teve_morte* (1 se mortos > 0) e *grave_ou_fatal* (1 se feridos_graves > 0 ou mortos > 0), usada como alvo do modelo preditivo.

Validação de domínio: Verificou-se que as coordenadas geográficas estavam dentro da Região Sul (latitude -35 a -22, longitude -57 a -44), que pessoas ≥ 1 em todos os registros e que a soma de mortos, feridos e ilesos era consistente com o total de pessoas. Nenhum registro precisou ser removido por violação de domínio. A coerência entre *classificacao_acidente* e as contagens de vítimas foi verificada sem inconsistências.

Ausências: As colunas *regional* (7 ausentes), *delegacia* (8) e *uop* (9) tiveram recuperação tentada via moda do município, sem sucesso para os casos restantes. As categorias *condicao_metereologica* = "Ignorado" (63 registros) e *sentido_via* = "Não Informado" (20 registros) foram convertidas para ausência explícita (NaN), pois representam ausência disfarçada de informação.

Variável multivalorada: *tracado_via* continha múltiplos valores separados por ponto e vírgula, com ordem variável. Foi normalizada (componentes ordenados alfabeticamente) e expandida em variáveis dummies binárias: *tracado_reta*, *tracado_curva*, *tracado_declive*, *tracado_aclive*, *tracado_intersecao_de_vias*, *tracado_ponte*, *tracado_rotatoria*, *tracado_viaduto*, entre outras.

Agrupamento de causas: A coluna *causa_acidente* apresentava 65 categorias, muitas com baixa frequência. As causas foram agrupadas em 8 macrocategorias: Falha de atenção ou reação, Comportamento de risco, Infração de trânsito, Álcool ou substâncias, Condição do veículo, Condição da via ou ambiente, Fator externo, Pedestre ou ciclista.

Após o pré-processamento, a base passou de 30 para 51 colunas, sem remoção de linhas.

2.3 Análise Exploratória de Dados (EDA)

A EDA foi dividida em dois notebooks. O primeiro (Notebook 01) focou no diagnóstico da qualidade dos dados: perfil de qualidade de todas as colunas, distribuições univariadas das variáveis numéricas (histogramas, boxplots, medidas descritivas), frequências das variáveis categóricas e identificação de ausências e anomalias.

O segundo notebook de EDA (Notebook 03) aprofundou as relações entre variáveis: tabelas de contingência com percentual na linha e índice de letalidade (mortos por 100 acidentes) para cada variável explicativa cruzada com *classificacao_acidente*, teste qui-quadrado e V de Cramér para ranquear as associações, e visualizações comparativas (barras 100% empilhadas, heatmap hora x dia da semana, comparação entre UFs). As análises priorizaram as variáveis listadas no objetivo do projeto: *causa_acidente*, *tipo_acidente*, *fase_dia*, *condicao_metereologica*, *tipo_pista*, *tracado_via*, *uso_solo*, *dia_semana*, *horario*, *uf* e *br*.

2.4 Ferramentas e organização do trabalho

O projeto foi desenvolvido em Python 3, com os notebooks executados no Google Colab. As principais bibliotecas utilizadas foram: *pandas* e *numpy* para manipulação de dados, *matplotlib* e *seaborn* para visualização, *scipy* para testes estatísticos (qui-quadrado) e *scikit-learn* para modelagem preditiva. O repositório está organizado com separação entre dados brutos (data/raw/, nunca sobrescritos), dados processados (data/processed/), notebooks numerados (notebooks/) e figuras exportadas (reports/figuras/).

3 RESULTADOS PARCIAIS E DISCUSSÃO

3.1 Diagnóstico da qualidade dos dados

A base apresentou qualidade geral elevada. Dos 30 campos originais, apenas 3 tinham ausências reais (*regional*, *delegacia*, *uop*), todas com menos de 0,1% de registros afetados. Outros 2 campos apresentavam ausências disfarçadas em categorias como "Ignorado" e "Não Informado", totalizando 83 registros (menos de 1% da base). Não foram encontradas duplicatas no identificador *id*.

Os principais problemas identificados e tratados foram:

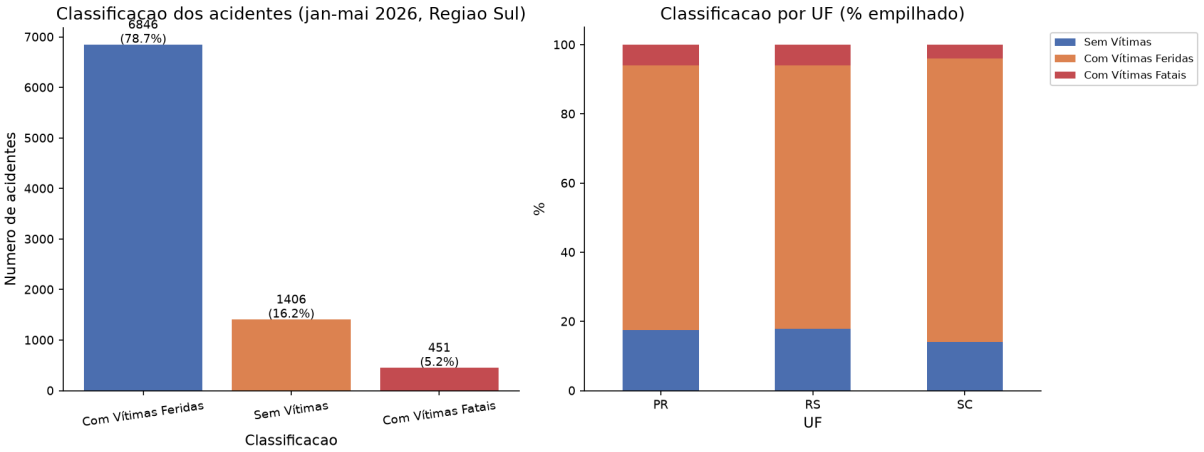
- Tipos incorretos: *data_inversa*, *horario*, *km*, *latitude* e *longitude* armazenados como texto;
- Variável multivalorada: *tracado_via* com valores compostos separados por ponto e vírgula;
- Alta cardinalidade: *causa_acidente* com 65 categorias, dificultando análise e modelagem;
- Desbalanceamento do alvo: a classe "Com Vítimas Fatais" representa apenas 5,2% dos registros.

Nenhum registro foi removido da base. A decisão de manter todos os registros, incluindo os com valores extremos em *pessoas* (máximo 50) e *mortos* (máximo 11), baseou-se na evidência de que esses casos correspondem provavelmente a acidentes reais com ônibus e são justamente os mais relevantes para o objetivo do projeto.

3.2 Resultados da análise exploratória

No período analisado (jan-mai/2026), foram registrados 8.703 acidentes em rodovias federais da Região Sul, resultando em 531 mortos, 2.165 feridos graves e 7.737 feridos leves. A classificação geral dos acidentes foi: Com Vítimas Feridas 6.846 (78,7%), Sem Vítimas 1.406 (16,2%) e Com Vítimas Fatais 451 (5,2%), conforme a Figura 1.

FIGURA 1 - Distribuição da classificação dos acidentes por UF (SC, PR, RS)

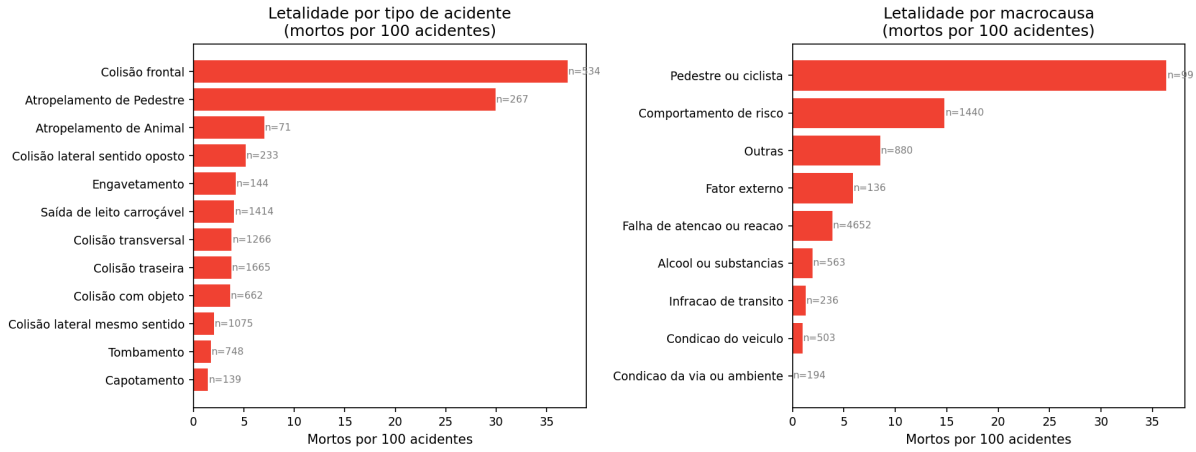


Fonte: elaborada pelos autores com base nos dados da PRF (2026).

A distribuição por estado revelou diferença relevante na letalidade: RS e PR apresentam índices similares (7,3 e 6,9 mortos por 100 acidentes, respectivamente), enquanto SC registra índice menor (4,7). Essa diferença pode refletir o perfil das rodovias em cada estado, mas não é possível afirmar causalidade sem dados de volume de tráfego.

A análise por tipo de acidente revelou que a colisão traseira é o tipo mais frequente (1.665 registros, 19,1%), seguida pela saída de leito carroçável (1.414, 16,3%) e colisão transversal (1.266, 14,5%). Contudo, ao calcular o índice de letalidade (mortos por 100 acidentes), o quadro muda: a **colisão frontal** é o tipo mais letal, com 37,1 mortos por 100 acidentes, seguida pelo **atropelamento de pedestre** (30,0). Esses dois tipos, embora não sejam os mais frequentes, concentram o maior risco de morte, como mostra a Figura 2.

FIGURA 2 - Índice de letalidade por tipo de acidente e por macrocausa (mortos por 100 acidentes)



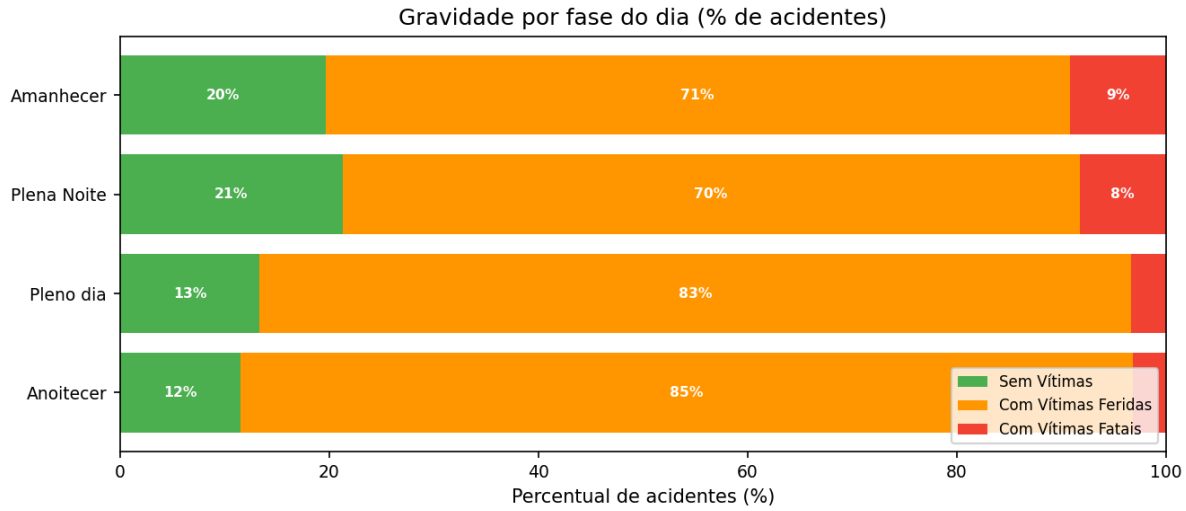
Fonte: elaborada pelos autores com base nos dados da PRF (2026).

Quanto às macrocausas, a categoria "Falha de atenção ou reação" é responsável por 4.652 acidentes (53,5% do total), consolidando as causas comportamentais como o principal grupo. Comportamento de risco (1.440, 16,5%) é a segunda categoria mais frequente, seguida pelo grupo "Outras" (880, 10,1%).

A análise do tipo de pista mostrou que acidentes em **pista simples** têm maior proporção de desfechos graves ou fatais (29,1%) em comparação com pista dupla (20,2%) e múltipla (21,8%), sugerindo que a infraestrutura da via está associada à gravidade dos acidentes. De forma análoga, acidentes em área rural (*uso_solo* = "Não") apresentaram proporção de desfechos graves/fatais de 26,6%, contra 22,0% em área urbana, o que é coerente com o maior risco em vias interurbanas sem separação de faixas e com velocidades mais altas.

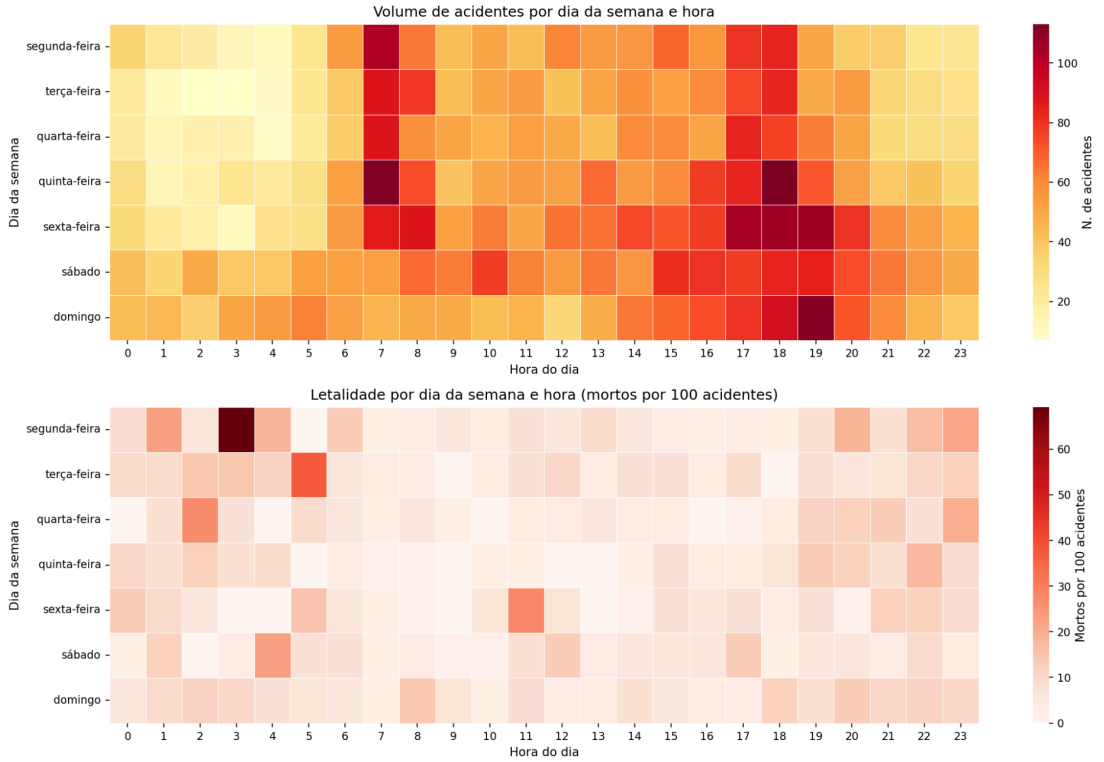
A análise por fase do dia indicou que o período de **amanhecer** concentra a maior proporção de acidentes graves ou fatais (29,1%), seguido pela plena noite (26,6%). O pleno dia, apesar de concentrar o maior número absoluto de acidentes, apresenta a menor proporção de desfechos graves (23,0%).

FIGURA 3 - Distribuição de gravidade por fase do dia (% de acidentes)



Fonte: elaborada pelos autores com base nos dados da PRF (2026).

FIGURA 4 - Volume de acidentes por dia da semana e hora do dia



Fonte: elaborada pelos autores com base nos dados da PRF (2026).

3.3 Relações, cruzamentos e insights iniciais

As análises de associação (V de Cramér) entre cada variável explicativa e a *classificacao_acidente* indicaram que as variáveis com maior associação são tipo_acidente e macrocausa, seguidas de fase_dia (V = 0,11) e uso_solo (V = 0,09). A variável tipo_pista apresentou V de Cramér de apenas 0,05, abaixo dessas quatro variáveis. Variáveis como *condicao_metereologica* e *fase_dia* apresentaram associações estatisticamente significativas pelo teste qui-quadrado, mas com V de Cramér baixo, indicando que o efeito é real, porém de magnitude limitada.

Um insight relevante é o contraste entre frequência e letalidade: os tipos de acidente mais comuns (colisão traseira, saída de leito carroçável) não são os mais letais. A colisão frontal representa apenas 6,1% dos casos, mas é responsável por 37,3% de todas as mortes do período. Esse padrão sugere que ações preventivas da PRF e do DNIT devem priorizar a redução de colisões frontais (sinalização, barreiras físicas de separação de faixas, fiscalização de ultrapassagens proibidas), mesmo que o número absoluto de casos seja menor.

Importante: associação estatística não implica causalidade. Além disso, a ausência de dados de volume de tráfego impede calcular o risco relativo por quilômetro percorrido. Todos os percentuais e índices de letalidade refletem os registros de acidentes, não o risco de um veículo ser envolvido em acidente ao percorrer determinado trecho.

3.4 Limitações identificadas

- **Período reduzido:** a base cobre apenas janeiro a maio de 2026 (5 meses). Eventos sazonais como feriados prolongados de verão e chuvas intensas no início do ano podem distorcer os padrões. O período não representa um ano completo.
- **Ausência de volume de tráfego:** sem dados de fluxo de veículos por trecho, não é possível calcular taxa de acidentes por quilômetro percorrido. Comparações entre rodovias ou estados com base em contagens absolutas não refletem risco real.
- **Cobertura restrita:** a base inclui apenas acidentes registrados pela PRF em rodovias federais. Acidentes em rodovias estaduais, municipais e vias urbanas não estão representados.
- **Qualidade do registro:** variáveis como *causa_acidente* dependem do julgamento do policial no momento do registro, o que pode introduzir subjetividade e variações entre regiões ou turnos.

- **Desbalanceamento do alvo binário:** o alvo *grave_ou_fatal* apresenta 24,6% de casos positivos. Sem compensação, um modelo trivial que sempre prediz "não grave" acertaria 75% dos casos, tornando a acurácia uma métrica inútil.
- **Features pós-acidente:** *tipo_acidente* e *causa_acidente* são registrados pela PRF após o acidente, não sendo variáveis de contexto pré-evento. O modelo tem valor associativo, mas não prediz gravidade antes do acidente acontecer.

4 ANDAMENTO DO PROJETO E PRÓXIMAS ETAPAS

Concluído até o momento:

- Notebook 01: EDA de diagnóstico (perfil de qualidade, distribuições, ausentes, duplicatas, primeiras comparações por UF, dia da semana, fase do dia e mês);
- Notebook 02: pré-processamento completo (conversão de tipos, criação de variáveis, validação de domínio, tratamento de ausências disfarçadas, normalização de *tracado_via*, agrupamento de macrocausas, criação de *grave_ou_fatal*);
- Notebook 03: EDA integrada e de correlação (V de Cramér, tabelas de contingência com percentual na linha, índice de letalidade por variável, visualizações para a AV1);
- Base tratada salva em data/processed/datatran_sul_tratado.csv (8.703 linhas x 51 colunas);
- Log de decisões de pré-processamento registrado em reports/decisoes_preprocessamento.csv;
- Dicionário de dados em reports/dicionario_dados.md;
- Notebook 04: modelo de classificação binária criado e executado (baseline, regressão logística, árvore de decisão e random forest).

Em andamento:

- Interpretação dos resultados do Notebook 04 (F1 macro, recall da classe grave/fatal, importância das features).

Próximas etapas:

- Notebook 05: preparação da base para o Looker Studio (exportação de fato_acidentes.csv, tabelas agregadas, KPIs);

- Montagem do dashboard no Looker Studio;
- Redação do artigo final e preparação da apresentação (AV2 em 03/12/2026).

5 CONSIDERAÇÕES PARCIAIS

O trabalho realizado até o momento permitiu caracterizar com precisão a base de dados da PRF para a Região Sul e identificar os principais padrões associados à gravidade dos acidentes. Os resultados da EDA indicam que o tipo de acidente, especialmente a colisão frontal e o atropelamento de pedestre, é a variável mais fortemente associada a desfechos fatais, mesmo representando uma parcela minoritária dos casos. A infraestrutura da via (pista simples versus dupla) e o contexto (área rural versus urbana) também apresentam associação relevante com a gravidade.

O objetivo geral do projeto é identificar fatores associados à gravidade para subsidiar ações preventivas da PRF e do DNIT. As evidências obtidas até aqui apontam direções claras para essa discussão: a redução de colisões frontais e o monitoramento de trechos de pista simples em área rural merecem atenção prioritária. As próximas etapas, especialmente a modelagem preditiva e o dashboard interativo, permitirão aprofundar e comunicar esses achados de forma mais acessível aos públicos-alvo.

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Foi utilizada a ferramenta Claude Code (Anthropic) para geração de código Python, estruturação dos notebooks e sugestão de análises. Os autores revisaram criticamente todo o conteúdo gerado, preencheram os blocos de interpretação e assumem integral responsabilidade pelo conteúdo final do trabalho.

REFERÊNCIAS

KNAFLIC, C. N. **Storytelling com dados**. Rio de Janeiro: Alta Books, 2019.

MCKINNEY, W. **Python para análise de dados**. 2. ed. São Paulo: Novatec, 2019.

POLÍCIA RODOVIÁRIA FEDERAL. **Dados abertos: acidentes**. 2026. Disponível em: portal.prf.gov.br/dados-abertos-acidentes. Acesso em: 24 set. 2026.

PROVOST, F.; FAWCETT, T. **Data science para negócios**. Rio de Janeiro: Alta Books, 2016.